



Universidade Federal  
de Santa Catarina

# Inteligência Artificial II

Engenharia de Computação

## Redes Auto-Organizáveis

Prof. Anderson Luiz Fernandes Perez

Email: [anderson.perez@ufsc.br](mailto:anderson.perez@ufsc.br)

# Sumário

- Introdução
- Aprendizado Competitivo e Hebbiano
- Redes ART
- Redes SOM

# Introdução

- Existem situações em que uma RNA precisa ser treinada sem um supervisor ou professor, sendo que a única informação conhecida está no conjunto de padrões de entrada.
- As RNA auto-organizável utilize o paradigma de aprendizado não-supervisionado, ou seja, utilizam um conjunto de regras de natureza local para o ajuste dos pesos.

# Introdução

- As redes neurais Auto-Organizáveis se assemelham mais às estruturas neurobiológicas que as redes supervisionadas.
- Esses modelos de RNA são muito utilizados em problemas de reconhecimento de padrões e agrupamento de dados em que as classes não são conhecidas *a priori*.

# Introdução

- Existem vários modelos de RNAs auto-organizáveis.
- Com relação ao algoritmo de treinamento utilizado, podem ser classificadas em:
  - Aprendizado competitivo;
  - Aprendizado hebbiano.

# Introdução

- Os algoritmos auto-organizáveis obedecem os seguintes princípios:
  - Modificações dos pesos associados às conexões tendem a aumentar esses pesos;
  - Limitação de recursos levam à competição entre as sinapses e à seleção das mais aptas em detrimento das outras;
  - Diferentes modificações nos pesos tendem a cooperar entre si.

# Introdução

- Para que seja desenvolvida uma função de processamento útil durante o processo de aprendizagem, é necessário que haja redundância nos padrões de entrada, sendo que:
  - A redundância nos padrões de entrada fornece o conhecimento incorporado à rede;
  - Parte desse conhecimento pode ser obtida por meio da observação de parâmetros estatísticos;
  - Ao incorporar esse tipo de conhecimento, a rede aprende a distinguir padrões nos dados de entrada;
  - Esse conhecimento é necessário para o aprendizado não-supervisionado.

# Aprendizado Competitivo e Hebbiano

- Aprendizado Competitivo
  - Os neurônios de saída competem entre si para se tornarem ativos.
  - O neurônio vencedor é chamado de *Best Matching*.
  - Padrões semelhantes são reunidos pela rede e representados numa única unidade, tornando-se detectores de características.



# Aprendizado Competitivo e Hebbiano

- Aprendizado Hebbiano
  - Criada pelo biólogo Donald Hebb em 1949.
  - A regra de Hebb determina que, se dois neurônios em cada lado de uma sinapse são ativados simultaneamente (sincronamente), logo os pesos daquela conexão devem ser seletivamente incrementados.
  - Se os neurônios forem ativados assincronamente, a sinapse será enfraquecida ou até mesmo excluída.
  - Se o neurônio pré-sináptico tiver grande influência na ativação do neurônio pós-sináptico, a conexão entre eles deve ser reforçada.

# Aprendizado Competitivo e Hebbiano

- Aprendizado Hebbiano
  - O processo de agrupamento é feito pela rede a partir das correlações de dados.
  - Todos os neurônios da camada de saída se conectam as unidades de entrada  $X$ , via pesos sinápticos  $w_{kj}$ .
    - $X = [X_1, \dots X_k, \dots X_p]$
  - O vetor de pesos sinápticos incidentes ao neurônio  $j$  é denotado por:
    - $w_j = [w_{1j}, w_{2j}, \dots, w_{pj}]$ ,  $j = 1, \dots, N$

# Aprendizado Competitivo e Hebbiano

- Aprendizado Hebbiano
  - Onde  $N$  é o número de neurônios da camada de saída.
  - A função de ativação  $h_j$  pode ser expressa por:

$$h_j = \sum_{i=1}^p x_i \cdot w_{ij} = x \cdot w_j, \quad j = 1, \dots, N$$

- Para se obter o melhor ajuste entre o vetor de entrada e o vetor de pesos sinápticos, deve comparar o produto ( $x \cdot w_j$ ) entre eles e selecionar o maior valor.

# Aprendizado Competitivo e Hebbiano

- Aprendizado Hebbiano

$$x \cdot w_{j^*} \geq x \cdot w_j, \forall j$$

- O neurônio  $j^*$  é considerado o neurônio vencedor para o vetor  $x$ .
- Logo:

$$h_j = \begin{cases} 1, & \text{se } j = j^* \\ 0, & \text{se } j \neq j^* \end{cases}$$

# Aprendizado Competitivo e Hebbiano

- Aprendizado Hebbiano
  - Uma regra simples de aprendizado competitivo padrão baseia-se na liberação de certa proporção do peso sináptico, pelos nós de entrada de um neurônio vencedor, e posterior distribuição uniforme desse peso em direção aos nós de entrada ativo.

$$\Delta w_j(t) \begin{cases} \eta[x - w_j(t)], & \text{se } j = j^* \\ 0, & \text{se } j \neq j^* \end{cases}$$

# Rede ART

- O uso de RNAs pode levar ao dilema da estabilidade-plasticidade, ou seja:
  - Como um sistema de aprendizado pode ser projetado para se adaptar indefinidamente em resposta a padrões significativos e ainda assim continuar indiferente a padrões irrelevantes?
  - Como pode um sistema de aprendizado preservar conhecimento previamente adquirido enquanto continua a aprender conhecimentos novos?
  - O que evita que um novo conhecimento se sobreponha a conhecimentos prévios?

# Rede ART

- A rede ART (*Adaptive Resonance Theory*) possui duas camadas de neurônios, sendo a camada de entrada  $F_1$ , que processa dados de entrada, e uma camada de saída  $F_2$ , que dispõe os padrões de treinamento em grupo.
- A camada de entrada e de saída estão conectadas por meio de dois conjuntos de conexões que ligam cada neurônio de uma camada a todos os neurônios da outra.

# Rede ART

- O primeiro conjunto de conexões são do tipo *feedforward*,  $\mathbf{w}$ , e assume valores reais, que segue da camada de entrada para a camada de saída.
- O segundo conjunto de conexões são do tipo *feedback*,  $\mathbf{b}$ , e assume valores binários e conecta os neurônios da camada de saída aos neurônios da entrada.
- O neurônio  $i$  da camada de entrada está conectado ao neurônio  $j$  da camada de saída através do peso  $w_{ji}$ .
- O neurônio  $j$  da camada de saída está conectado ao neurônio  $i$  da camada de entrada através do peso  $b_{ij}$ .



# Rede ART

- Os pesos *feedforward* e *feedback* são também conhecidos com filtros adaptativos, pois adaptam dinamicamente seus valores para possibilitar o aprendizado de novos padrões.
- A rede também possui um conjunto de pesos bipolares não-adaptáveis entre os neurônios da camada de saída.
- O peso entre dois neurônios da camada de saída, e -1 se este liga dois neurônios distintos, e +1 se ele liga sua saída a si mesmo.
- Para cada camada da rede ART 1 há uma unidade externa de controle, unidade  $G_1$  para a camada de entrada e unidade  $G_2$  para a camada de saída.

# Rede ART

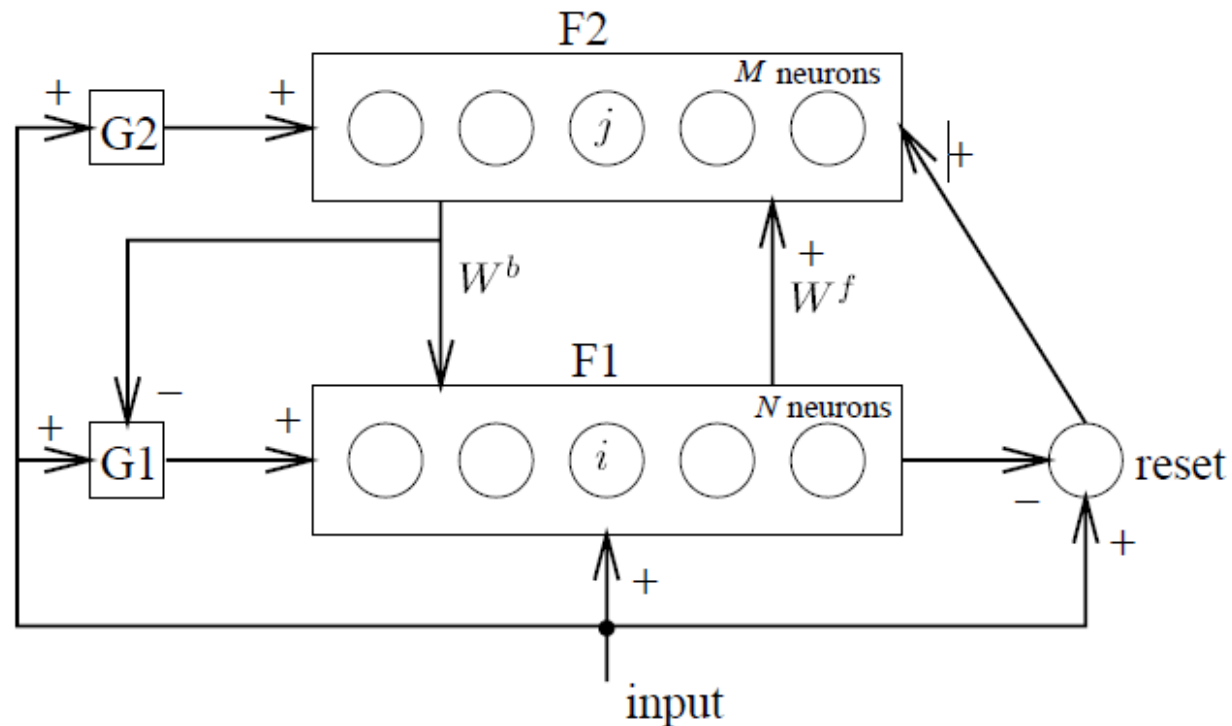
- A unidade  $G_1$  determina o fluxo de dados para camada de entrada.
- A unidade  $G_2$  possui duas funções:
  - Determinar o fluxo de dados para a camada de saída;
  - Habilitar ou desabilitar neurônios da camada de saída.
- A unidade  $G_2$  assume o valor 1 se uma entrada válida for apresentada à rede e 0 após desabilitar os neurônios da camada de saída e resetar seus estados de ativação para 0.

# Rede ART

- Entre a camada de entrada e a camada de saída existe um mecanismo de reset, responsável por verificar a semelhança entre um vetor de entrada e um dado vetor protótipo, utilizando um limiar de vigilância ( $p$ ).
- O limiar  $p$  determina se um padrão de entrada pode ser incluído em dos grupos existentes.

# Rede ART

- Visão Geral da Rede ART 1



# Rede ART

- O algoritmo de aprendizado da rede ART 1 é não-supervisionado e pode ser ativado a qualquer momento.
- O aprendizado para uma rede ART 1 pode ser do tipo:
  - Rápido
  - Lento
- No aprendizado rápido, os pesos convergem para valores ótimos em poucos ciclos, geralmente em apenas um ciclo de treinamento.
- No aprendizado lento, os pesos são ajustados lentamente em vários ciclos de treinamento, possibilitando um ajuste melhor dos pesos da rede aos padrões de treinamento.

# Rede ART

- A rede ART 1 é muito sensível a variações em seus parâmetros durante o treinamento. O parâmetro mais crítico é o limiar de vigilância ( $p$ ) que controla a resolução do processo de classificação.
- Se  $p$  assume um valor baixo ( $< 0,4$ ), a rede permite que padrões não muito semelhantes sejam agrupados no mesmo grupo, criando poucas classes.
- Se for atribuído um valor alto a  $p$ , pequenas variações nos padrões de entrada levarão à criação de novas classes.
- Os valores iniciais do vetor de pesos *feedforward* e *feedback* ( $w$ ) são determinados pela equação:

$$w_{ji}^b(0) = 1$$
$$w_{ij}^f(0) = \frac{1}{1 + N}$$

# Rede ART

- Cada neurônio da camada de entrada pode receber três sinais, sendo:
  - Um sinal do vetor de entrada;
  - Um sinal de feedback da camada de saída;
  - Um sinal da unidade de controle  $G_1$ .
- Um neurônio da camada de entrada somente será ativado se receber pelo menos dois sinais excitatórios. Essa regra é denominada regra dos dois terços (2/3).
- Na fase de reconhecimento, o vetor de entrada e o sinal de controle  $G_1$  são enviados à camada de entrada, onde será aplicada, a cada neurônio, a regra dos 2/3.

# Rede ART

- O vetor resultante é comparado com todos os vetores de pesos feedforward,  $w$ , para encontrar o mais semelhante.
- A comparação é realizada calculando o produto interno entre o vetor  $d$  resultante e o vetor de pesos feedforward para cada neurônio da camada de saída.

$$y_i' = \sum_{j=1}^N w_{ij} f(t) x_i;$$

- $y_j$  é a ativação do neurônio de saída  $j$ , definido pelo produto interno entre seu vetor de pesos  $w_j$  e seu vetor de entrada  $x$ .
- O neurônio da camada de saída com maior valor de ativação é selecionado como provável grupo para armazenar o novo padrão.



# Rede ART

- Com o sinal da unidade de controle  $G_1$  é igual a 0, ocorre uma operação AND entre o vetor protótipo do neurônio selecionado e o vetor de entrada, produzindo um novo vetor, chamado vetor de comparação z.
- O vetor z é enviado ao mecanismo de reset junto com o vetor de entrada.
- O mecanismo de reset é responsável por testar a similaridade entre o vetor de entrada e o vetor de comparação.



# Rede ART

- Algoritmo da Rede ART 1

1. Inicializar pesos e parâmetros;
2. **Repita**
  3. **Para todo** cada padrão de treinamento **faça**
    4. **Enquanto** houver neurônios não desabilitados **faça**
      5. Definir neurônio vencedor;
      6. Comparar protótipo do vencedor com a entrada;
      7. **Se** comparação > limiar de vigilância **então**
        8. Atualizar os pesos do neurônio vencedor;
      9. **Senão**
        10. Desabilitar neurônio vencedor;
      11. **Fim se**
    12. **Fim enquanto**
    13. **Se** nenhum neurônio teve seus pesos atualizados **então**
      14. Incluir novo neurônio na rede;
      15. Ajustar seus pesos utilizando padrão de entrada;
    16. **Fim se**
    17. Habilitar neurônios desabilitados;
  18. **Fim para**
  19. **Até que** conjunto de protótipos não mudar

# Rede SOM


- A rede do tipo SOM, *Self Organizing Maps*, foi criada na década de 90 por Teuvo Kohonen.
- São baseadas no mapa topológico presente no córtex cerebral.
- Neurônios topologicamente próximos tendem a responder a padrões ou estímulos semelhantes.

# Rede SOM

- A ordenação topológica é resultado do uso de *feedback* lateral entre as células do córtex cerebral.
- O feedback lateral é geralmente modelado em RNAs por uma função conhecida por chapéu mexicano, onde:
  - cada neurônio influencia o estado de ativação de seus neurônios vizinhos de três formas possíveis:

# Rede SOM

- Chapéu Mexicano



# Rede SOM

1. Excitatória: se os vizinhos estão próximos a ele (por exemplo, dentro de uma área de raio  $R_1$ )
2. Inibitória: se os vizinhos estão fora da área anterior, mas dentro de uma segunda área (por exemplo, dentro de uma área de raio  $R_2$ , mas fora da área de raio  $R_1$ , onde  $R_2 > R_1$ )
3. Levemente Excitatória: se os vizinhos estão fora das áreas anteriores mas dentro de uma terceira área (por exemplo, dentro de uma área de raio  $R_3$ , mas fora das áreas de raios  $R_1$  e  $R_2$ , onde  $R_3 > R_2 > R_1$ )

# Rede SOM

- A rede SOM funciona da seguinte maneira:
  - Quando um padrão  $\mathbf{p}$  é apresentado, a rede procura a unidade mais parecida com  $\mathbf{p}$ .
  - Durante seu treinamento, a rede aumenta a semelhança do neurônio escolhido e de seus vizinhos ao padrão  $\mathbf{p}$ .
  - A rede constrói um mapa topológico onde neurônios que estão topologicamente próximos respondem de forma semelhante a padrões de entrada semelhantes.

# Rede SOM

- Nas redes SOM os neurônios das camadas de saída competem entre si para se tornarem ativos, ou seja, para ver quem gera o maior valor de saída.
- A competição entre os neurônios é conhecida como *winners-takes-all*, ou seja, o vencedor leva tudo.
- Quando um neurônio vence uma competição, produzindo a maior saída para a uma dada entrada, não apenas ele, mas também os neurônio localizados na sua vizinhança têm seus pesos ajustados.

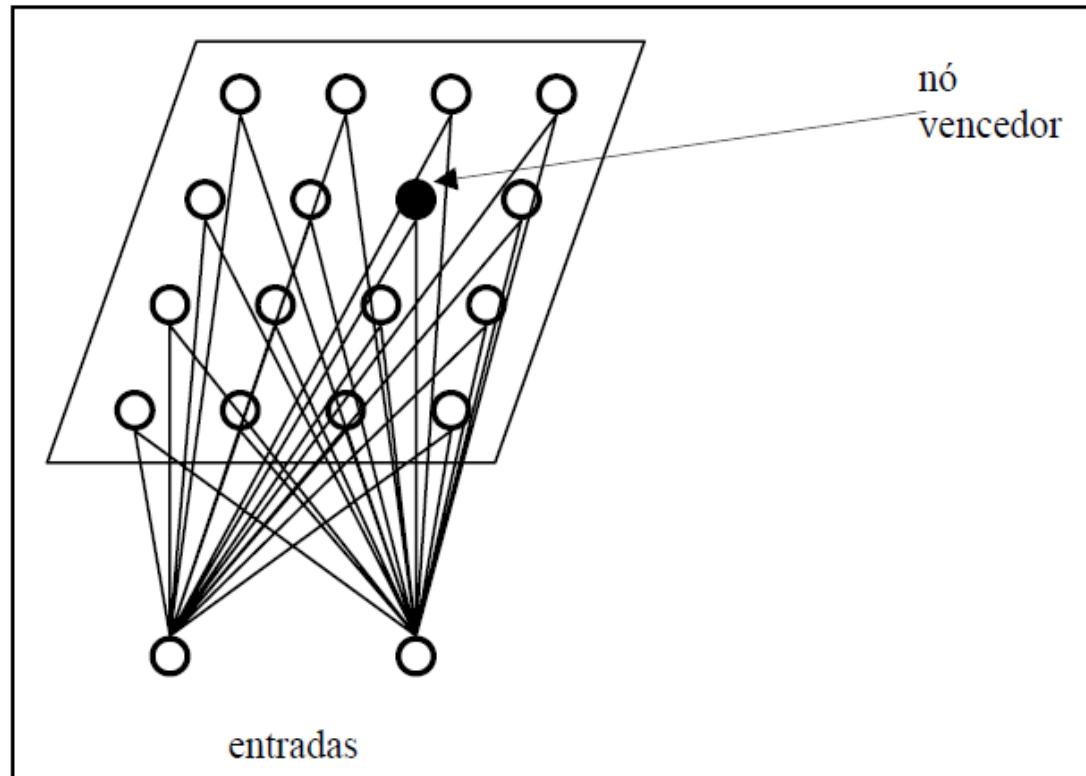


# Rede SOM

- Em uma rede SOM os neurônios se organizam em uma grade ou reticulado.
- Cada neurônio recebe todas as entradas e funciona como um discriminador ou extrator de características.
- A saída é formada pela saída de todos os neurônios que compõem a rede.
- A função de ativação da rede SOM é baseada na medida de distância euclidiana.

# Rede SOM

- Visão Geral de uma Rede SOM



# Rede SOM

- Algoritmo da Rede SOM

1. Inicializar pesos e parâmetros;
2. **Repita**
  3. **Para todo** cada padrão de treinamento **faça**
  4. Definir neurônio vencedor;
  5. Atualizar os pesos deste neurônio e de seus vizinhos;
  6. **Se** o número do ciclo for múltiplo de N **então**
    7. Então reduzir taxa de aprendizado;
  8. **Fim se**
9. **Fim para**
10. **Até que** mapa de características não mudar